MongoDB Tokyo 2012 January 18th Tokyo, Japan

mongo-hadoopで始める大規模ログ解析 〜低コストへの新たな道〜 BigData Analysis with mongo-hadoop

> Daichi Morifuji/muddydixon ニフティ株式会社/NIFTY

自己紹介/myself

- @muddydixon
- id:muddydixon



- 自然言語処理:形態素列検索・置換システム
- 言語発達の計算機シミュレーション(ElmanNet+SOMみたいな)

就職

- 検索エンジン(の広告最適化とか
- コンテンツマッチエンジンの設計開発とか
- エンジニアサポートの中の人とか
- データマイニング部門(←NEW 部門ができたよ!)



ログの解析好きですか?ログの解析していますか?

正直、大企業じゃないときついっす

リソース・知識も無いし

@doryokujin さんがどうかしてる 「#doryokujinnero」なんてタグが生まれ るくらいじゃないと厳しい

一般人が「#...nero」とか tag付けられない範囲で ログを解析したりする システムを頑張ってみた!

Requeirements

Functional Requeirements

- Ad hoc query for API
- OLAP for survay
- Distributed Processing bigdata analysis

Non-Functional Requeirements

- Easily Works for non-big company
- Easy maintenance to some degree for non-experts
- Not Data loss for non-holiday works

All for healthy sleeping

Contents

- 1. MongoDB
- 2. Hadoop
- 3. mongo-hadoop
- 4. Advance
- 5. Conclusion

MongoDB

Cons

- OOM occurs in Map/Reduce
- Rich Resources (memory / disc)

Pros

- Schemaless
- Full Index
- Replication & High Availability
- Auto Sharding

Hadoop

Cons

- Difficulty in Operation / Tuning
- Many Daemons
- HBase needs more Daemons
- hive spends much time

Pros

- Scaleout
- Calculate Large Data by Map/Reduce
- Scalable FileSystem (HDFS) supported

Requeirements again

- Ad hoc query for API
- OLAP for survay
- Distributed Processing bigdata analysis
- Easily Works for non-big company
- Easy maintenance to some degree for non-experts
- Not Data loss for non-holiday works

and we want

- Calculate Large Data Easily (No OOM Killer)
- No more Daemons
- No more non-"Healthy" State

Cons. in MongoDB vs. Hadoop

MongoDB

Difficulty in Calculating Large Data

Hadoop

- Too much Daemons
- Often not "Healthy" warning
- Cannot Find data in a moment (HBase is too difficalt to operate)

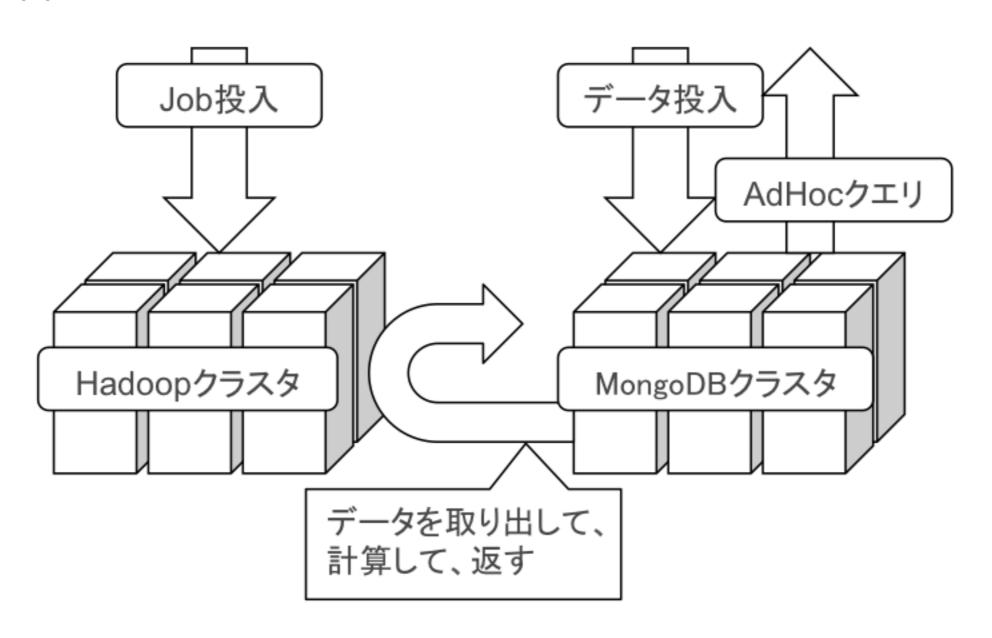
mongo-hadoop

mongo-hadoop

What?

mongo-hadoop is Adapter. It enables Hadoop to access MongoDB data.

mongo-hadoop supports shards and chunks environment



Sample

Driver

```
MongoConfigUtil setInputURI conf, "mongodb //localhost/test in" ); // set input hcst, db, ccllecticn
MongoConfigUtil setOutputURI conf, "mongodb //localhost/test out" ); // set cutput hcst, db, ccllecticn
```

Mapper

```
public void map Object key, BSONObject value, Context context ) throws IOException, InterruptedException
   if didStart )
       log info 'map starting, config ' + context getConfiguration ) );
       didStart = true;
            System cut println 'key. ' + key );
   //
               System cut println 'value ' + value );
    //
   String str = value get 'line' ) toString );
   if str = null ).
       final StringTokenizer itr = new StringTokenizer str );
       while itr hasMoreTokens | )
           word set itr nextToken ) ;
           context write word, one );
```

we gotta in mongo-hadoop

MongoDB Hadoop

not Easy Calculate Large Data

Hadoop MongoDB

- Too much Limited Daemons
- Often not "Healthy" warning Replica set and sharding
- Cannot Can Find data in a moment (HBase is too difficalt to operate)

Advance

Hadongo

Features

- use BSONWritable
- use Common Mapper
- use Reducer class for Combinator
- merge multipleInputResources (now pull requesting)

use **BSONW**ritable

- BSONWritable is used as elements of Map/Reduce in Hadongo
 - Mapper<Object, BSONObject, BSONWritable, BSONWritable>
 - Reducer<BSONWritable, BSONWritable, BSONWritable, BSONWritable>
- using BSON means below:
 - We can use "schemeless objects" consisted of String, Number, Boolean,
 Object, List
 - We should handle them such as check existence, type validation.

use Common Mapper

- In hadoop: we create Mappers/Reducers for distinct Data Resouces.
- In hadongo: we create common Mappers/Reducers for distinct Processing Logics and use it to analyze many valiations.

*Note: check type and existance of target values your own self.

use Reducer class for Combinator

- use BSONWritable in
 - Mapper output<BSONWritable key, BSONWritable val>
 - Reducer input<BSONWritable key, BSONWritable val>
 - Reducer output<BSONWritable key, BSONWritable val>
- Therefore Reducer is used for Combinator Class
- And finally reducing processing is distributed in Many Mapper Processes

merge multipleInputResources (now pull requesting)

- in MongoDB: cannot merge multiple input resouces (collection)
- in practice: the case when Logs and Users are merged is asked

plz merge @rit (@10gen)!!

hadongo (not public)

Using hadongo library, we can summarize like that

You can do it for nested keys

```
hadoop jar hodongo com nifty hadongo HadongoDriver

-in localhost 27C17/logs searchLogs

-out localhost 27C17/summarize searchWordRankings

-mapper com nifty hadongo mapred CountMapper

-reducer com nifty hadongo mapred CountReducer

-key "spec query" []

-query ts "$gt" 12938C76CCCCC[, "$lt" 1294326CCCCCCC[]

-fields "spec query" 1]
```

Hadongo releases us to develop Mapper/Reducer for each summarizing Job.

Only change options!

Conclusion

- Ad hoc query for API via MongoDB
- OLAP for survay via MongoDB
- Distributed Processing bigdata analysis via Hadoop
- Easily Works for non-big company via MongoDB
- Easy maintenance to some degree for non-experts via MongoDB
- Not Data loss for non-holiday works via MongoDB

All for healthy sleeping

Future works

Future works

- simplify BSONDecoder Class
- trim mappers for out of range chunks (now development)

NIFTY Cloud ニフティクラウド クラウドサービス特長「ニフティクラウドとは」

@nifty

NIFTY Cloud 特長

♠ クラウドトップ>特長

ニフティクラウドとは



ニフティクラウドは、仮想化されたサーバーリソースを必要なときに必要な分だけ、オンデマンドで借りられる、純国産の「パブリック型クラウドコンピューティングサービス」です。

お客様が提供されるサービスのサーバー環境として「ニフティクラウド」をご利用いただけば、サービス稼働後の負荷状況に応じて、サーバーの台数やスペックを増やしたり減らしたりできるので、過剰投資のリスクを最小限に抑えられます。

需要変動の波が激しいサービスに

1

リードタイムはわずか5分

ニフティクラウドのご利用開始後、サーバーの追加・削除や、スペック変更などにかかる時間は、わずか5分程度。リードタイム分のリソースの余剰を考慮する必要がなくなります。

2

サーバーの増強・縮退が自在

サーバーの追加・削除や、スペック変更などの操作は、Web上のコントロールパネル(管理画面)から オンデマンドに行えます。

アクセスの波に応じて、サーバーリソースの規模を最適化でき、**インフラコストが「変動費」**になります。

お申し込み、資料請求はこちら

お申し込み

資料請求

お問い合わせ

初期費用〇円



Site Menu

- → ニフティクラウドトップ
- → ニフティクラウドとは
- 信頼性への取り組み
- 節電対策として
- > 仕様・機能
- ・ サーバータイプ・仕様



「ユーザの生活を楽しくする」 「より楽しくお金を払ってもらえる」 「ビジネスを加速させる」 DataMiner/DataScientist を募集しています。

D @muddydixon